

Predikcija sistemskih metrika virtualne mašine na Bitbrains skupu podataka

Izveštaj za projekat iz Računarske inteligencije

Autor: [Dimitrije Spasojević]

Repozitorijum: system-metrics-forecasting

Skup podataka: GWA-T-12 BitBrains, jedan VM (oznaka 1000)

Sažetak. U radu je razmotren problem jednokoračne predikcije šest sistemskih metrika virtualne mašine centralni procesor, memorija, protok pri čitanju i pisanju na disk, kao i primljeni i poslati mrežni saobraćaj. Polazište rada su javno dostupni Bitbrains tragovi poslovno kritičnih cloud opterećenja. Najpre su implementirani jaki linearni i naivni baselines, a zatim nelinearni rekurentni model zasnovan na LSTM mreži i eksperimentalni latentni pristup zasnovan na autoenkoderu i GRU prediktoru. Na posmatranom VM-u linearni modeli drastično popravljaju rezultat u odnosu na persistence baseline, dok LSTM daje dodatno, ali umereno poboljšanje. Autoenkoder sa predikcijom u latentnom prostoru nije nadmašio direktni LSTM. Glavni doprinos rada je transparentna i poštena reprodukcija više klasa modela nad istim skupom podataka, uz jasnu analizu situacije u kojoj kompleksniji latentni pristup nije doneo dobitak.

1. Uvod

Predikcija opterećenja cloud infrastrukture je važna zato što utiče na planiranje kapaciteta, automatsko skaliranje, raspodelu resursa i energetske efikasnost. Ako se buduće opterećenje proceni previše nisko, kvalitet usluge može opasti; ako se proceni previše visoko, sistem nepotrebno troši resurse i novac. Zbog toga je predikcija vremenskih serija upotrebe procesora, memorije, diska i mreže česta tema u literaturi o cloud sistemima (Adegboyega 2017; Lackinger et al. 2024).

U ovom radu koristi se javni skup tragova GWA-T-12 BitBrains, koji sadrži performansne metrike za 1.750 virtualnih mašina iz distribuiranog poslovnog data centra. Svaki fajl predstavlja jedan VM i sadrži metrike kao što su CPU, memorija i diskovno-mrežni protoci. BitBrains tragovi su zanimljivi zato što potiču iz realnog okruženja poslovno kritičnih aplikacija, pa sadrže nelinearna i heterogena opterećenja kakva se u praksi zaista sreću (Shen, van Beek, and Iosup 2015; @Large Research Group n.d.).

U dosadašnjoj literaturi statistički modeli poput ARIMA i VAR često služe kao jake početne reference, dok se rekurentne neuronske mreže koriste za hvatanje nelinearnih i dugoročnih zavisnosti. LSTM je uveden upravo da ublaži problem nestajanja gradijenata kod klasičnih RNN mreža i da omogući učenje dužih zavisnosti u sekvencama (Hochreiter and Schmidhuber 1997). Kasniji radovi u cloud domenu pokazuju da multivarijantni i duboki modeli često nadmašuju jednostavne univarijantne pristupe, ali i da rezultat snažno zavisi od prirode samog workload-a (Dang-Quang and Yoo 2022; Ouhamme and Hadi 2019).

Pošto latentne reprezentacije ponekad mogu da izdvoje stabilniju strukturu signala od direktnog rada u originalnom prostoru, u radu je dodatno ispitan i jednostavan autoenkoder. Ovaj deo ne pretenduje na originalni novi model, već predstavlja skromnu reprodukciju ideje da se deo predikcije izvrši u kompresovanom latentnom prostoru, što je u novijoj literaturi česta linija istraživanja za vremenske serije (Cai et al. 2023).

Rad	Osnovna ideja	Veza sa ovim radom	Napomena
Shen et al. 2015	Karakterizacija Bitbrains workload tragova u poslovnim cloud data centrima.	Obezbeđuje kontekst i opravdanje izbora skupa podataka.	Ne rešava direktno naš forecasting zadatak, ali opisuje podatke.
Adegboyega 2017	Poređenje statističkih time-series modela za cloud workload prediction.	Motiviše upotrebu jakih baseline modela i pažljivo poređenje.	Pokazuje da izbor modela zavisi od tipa workload-a.
Ouhamme and Hadi 2019	Hibridni VAR + stacked LSTM za multivarijantnu predikciju.	Motiviše kombinovanje linearnih i nelinearnih pristupa.	U radu se koristi samo CPU i memorija, dok ovde koristimo šest metrika.

Dang-Quang and Yoo 2022	Multivarijantni Bi-LSTM za proaktivno autoskaliranje.	Potvrđuje da duboki multivarijantni modeli mogu biti korisni.	Koristi širi eksperimentalni okvir i kompleksniji model.
Cai et al. 2023	Latentna reprezentacija i forecast u autoenkoderskom/VAE okviru.	Motiviše eksperimentalni latentni baseline.	Naš autoenkoder je jednostavniji i deterministički.

Tabela 1. Kratak pregled literature na koju se naslanja implementirano rešenje.

2. Opis rešenja

Predloženo rešenje je organizovano kao transparentan eksperimentalni tok koji ide od obrade podataka, preko snažnih baseline modela, do nelinearnih i latentnih pristupa. Cilj nije da se tvrdi originalnost osnovnih algoritama, već da se reprodukuju reprezentativne metode iz literature i proveriti kako se ponašaju nad jednim konkretnim Bitbrains VM tragom.

2.1. Podaci i pretprocesiranje

Za eksperiment je korišćen jedan VM iz Bitbrains skupa podataka, označen kao VM 1000. Zadržano je šest dinamičkih metrika: CPU usage [%], Memory usage [KB], Disk read throughput [KB/s], Disk write throughput [KB/s], Network received throughput [KB/s] i Network transmitted throughput [KB/s].

Sirovi CSV je već uzorkovan na korak od pet minuta, pa nije bila potrebna dodatna resamplacija vremenske ose. Nedostajuće vrednosti su popunjene metodom forward-fill, a preostale početne praznine nulama. Nakon toga je urađena hronološka podela na trening, validacioni i test segment u odnosu 70% / 15% / 15%. Standardizacija je vršena isključivo na trening delu, a iste parametre sklera dobili su validacioni i test segment, čime je izbegnuto curenje informacija iz budućnosti.

Skup	Broj vremenskih tačaka	Udeo
Trening	6048	70%
Validacija	1296	15%
Test	1296	15%

Tabela 2. Podela posmatranog niza na trening, validaciju i test.

2.2. Formiranje prozora i ciljni zadatak

Zadatak je formulisan kao jednokoračna multivarijantna predikcija. Za svaki trenutak t model dobija poslednjih L posmatranja i treba da predvidi vektor metrika u trenutku $t+1$. U baznoj konfiguraciji uzeto je $L = 12$, što odgovara jednom satu istorije pri koraku od pet minuta.

Ova transformacija je urađena funkcijom `make_windows`, koja od ulaza oblika (T, D) formira sekvence oblika (N, L, D) . Za linearni ridge model sekvence se zatim flatten-uju u vektore dužine $L \cdot D$. Pri evaluaciji nad validacionim i test skupom korišćen je isti fer protokol za sve modele: početni kontekst validacije dolazi iz kraja trening segmenta, a početni kontekst testa iz kraja trening + validacija segmenta.

Primer ulaza za $L=3$	Vremenski trenuci	Cilj
-----------------------	-------------------	------

$[x(t-2), x(t-1), x(t)]$	tri uzastopna vektora sa po 6 metrika	$x(t+1)$
--------------------------	---------------------------------------	----------

Tabela 3. Jednostavan vizuelni primer sekvencijalnog kodiranja zadatka.

2.3. Baseline modeli

Korišćena su tri baseline pristupa. Persistence baseline postavlja predikciju sledećeg koraka jednaku poslednjem viđenom vektoru u prozoru. Ovaj baseline je često iznenađujuće jak i zato je važan u svakom ozbiljnom eksperimentu sa vremenskim serijama.

Ridge regression koristi iste prozore, ali ih spljoštava u jedan veliki ulazni vektor i uči linearnu višestruku regresiju sa L2 regularizacijom. Na taj način se dobija jasan linearni autoregresioni baseline.

VAR model predstavlja standardno multivarijantno autoregresiono proširenje i modeluje svaku komponentu kao linearnu funkciju sopstvenih prošlih vrednosti i prošlih vrednosti ostalih komponenti. U implementaciji je red VAR modela biran po AIC kriterijumu na trening skupu, sa maksimalnim dozvoljenim zaostatkom 12.

2.4. LSTM model

Kao glavni nelinearni model korišćen je jednostavan sequence-to-one LSTM. Ulaz modela je sekvenca oblika $(L, 6)$, LSTM je obrađuje kroz jednu skrivenu rekurentnu reprezentaciju veličine 32, a zatim linearni izlazni sloj mapira poslednje skriveno stanje u predikciju sledećeg šestodimenzionog vektora.

Model je treniran optimizatorom Adam, uz MSE gubitak, batch size 64, learning rate 10^{-3} , blagu L2 regularizaciju i early stopping na osnovu validacione RMSE vrednosti. Uvedeno je i gradient clipping ograničenje radi stabilnijeg treninga.

2.5. Autoenkoder i latentna predikcija

Kao dodatni eksperimentalni pravac korišćen je jednostavan feed-forward autoenkoder. Njegov encoder projektuje originalni šestodimenzioni vektor u latentni prostor dimenzije 3, dok decoder pokušava da rekonstruiše originalni ulaz. U drugoj fazi se u latentnom prostoru formiraju sekvence i nad njima se trenira GRU prediktor koji procenjuje sledeći latentni vektor.

Ovaj pristup nije doslovna reprodukcija nekog konkretnog rada iz literature, već pojednostavljena implementacija ideje da latentna reprezentacija može da filtrira šum i naglasi strukturu korisnu za forecasting. Zbog te pojednostavljenosti dobijeni rezultat treba posmatrati kao dodatni eksperimentalni baseline, a ne kao punopravni konkurent savremenim varijacionim ili hibridnim latentnim arhitekturama.

2.6. Metrike

Korišćene su dve grupe metrika. Prva grupa su MAE i RMSE u standardizovanom prostoru; te metrike su pogodne za fer poređenje modela kada feature-i imaju veoma različite skale. Druga grupa su iste metrike u originalnim jedinicama, dobijene invertovanjem skalera, što omogućava interpretaciju greške po metrikama i u fizički razumljivim jedinicama.

3. Eksperimentalni rezultati


3.1. Eksperimentalno okruženje

Implementacija je realizovana u Python-u 3.10 u okviru lokalnog virtuelnog okruženja. Korišćene biblioteke su NumPy, pandas, scikit-learn, statsmodels i PyTorch. Eksperimenti su izvršavani na lokalnoj Linux mašini sa Pop!_OS operativnim sistemom, pri čemu je PyTorch radio u CPU režimu.


3.2. Kvantitativni rezultati

Model	Test RMSE (scaled)	Test MAE (scaled)	Test RMSE (orig.)	Napomena
Persistence	1.2677	0.5565	215031.69	Naivni baseline
Ridge	0.5157	0.1936	40287.53	Najbolji linearni model
VAR	0.5158	0.1938	40253.50	Praktično izjednačen sa Ridge
LSTM	0.4866	0.1749	54934.73	Najbolji ukupni rezultat
AE + GRU latent	0.5359	0.2061	72117.50	Latentan pristup bez dobitka

Tabela 4. Glavni rezultati na test skupu za VM 1000.



Slika 1. Test RMSE u standardizovanom prostoru za sve razmatrane modele.



Slika 2. Poređenje per-feature RMSE u standardizovanom prostoru.

3.3. Diskusija rezultata

Rezultati pokazuju da posmatrani VM ima dovoljno dinamike da persistence baseline ne bude konkurentan ozbiljnijim modelima. To je važan signal da je izabrani niz pogodan za forecasting i da ne predstavlja degenerisan slučaj sa dugim konstantnim segmentima.

Ridge i VAR ostvaruju gotovo identične rezultate. To je logično, jer oba modela u suštini koriste linearnu autoregresionu strukturu nad istim skupom metrika. Na ovom VM-u linearna zavisnost već objašnjava veliki deo dinamike, što se vidi po padu test RMSE sa 1.2677 na približno 0.5157.

LSTM dodatno smanjuje grešku na 0.4866. Poboljšanje u odnosu na Ridge/VAR nije ogromno, ali je stabilno i dovoljno veliko da opravda tvrdnju da u posmatranom nizu postoje i nelinearne zavisnosti koje linearni modeli ne zahvataju u potpunosti. U isto vreme, rezultat pokazuje i da linearni baselines ne smeju biti potcenjeni: najveći deo dobitka dolazi već prelaskom sa persistence na linearne modele, a ne tek uvođenjem dubokih mreža.

Latentni pristup sa autoenkoderom i GRU prediktorom nije nadmašio direktni LSTM, iako je značajno bolji od persistence baseline-a. To sugerise da autoenkoder uspešno uči kompaktnu reprezentaciju, ali da na ovom konkretnom VM-u kompresija ne donosi informaciju koja bi forecasting učinila lakšim od direktnog rada u originalnom prostoru.

U odnosu na literaturu, ovakav ishod je umereno konzervativan. Radovi poput Dang-Quang and Yoo (2022) i Ouhamme and Hadi (2019) često prijavljuju veću korist složenijih dubokih ili hibridnih modela, ali rade na drugačijim podskupovima podataka, sa drukčijim izborom feature-a i često sa bogatijim arhitekturama. Zbog toga se

poređenje sa literaturom u ovom radu mora čitati pre svega kvalitativno, a ne kao strogo numeričko takmičenje pod istim uslovima.

4. Zaključak

U radu je implementiran i upoređen niz pristupa za jednokoračnu predikciju šest sistemskih metrika virtualne mašine iz Bitbrains skupa podataka. Eksperiment je organizovan po principu od jednostavnijih ka složenijim modelima: persistence baseline, ridge regresija, VAR, LSTM i latentni autoenkoder + GRU pristup.

Najvažniji nalaz je da posmatrani VM 1000 nije trivijalan slučaj i da linearni modeli ostvaruju veliko poboljšanje u odnosu na persistence baseline. LSTM zatim donosi dodatno, ali umereno poboljšanje i predstavlja najbolji model u celom eksperimentu. Sa druge strane, latentni pristup nije uspeo da nadmaši direktni LSTM, što je važan negativan rezultat koji treba pošteno prijaviti jer pokazuje da složeniji pipeline ne garantuje automatski bolju predikciju.

Kao pravac daljeg rada nameću se najmanje tri proširenja. Prvo, trebalo bi testirati veći broj VM-ova i proveriti da li se isti rang modela zadržava i na drugim workload tipovima. Drugo, moguće je ispitati bogatije rekurentne ili hibridne arhitekture, na primer Bi-LSTM ili VAR-LSTM kombinacije iz literature. Treće, latentni deo bi mogao biti unapređen varijacionim ili sekvencijalnim autoenkoderom koji bi bolje modelovao vremensku dinamiku od jednostavnog determinističkog autoenkodera po vremenskoj tački.

5. Literatura

- Adegboyega, Abiola. 2017. "Time-Series Models for Cloud Workload Prediction: A Comparison." U Proceedings of the IFIP/IEEE International Symposium on Integrated Network Management. PDF.
- Cai, Borui, Shuiqiao Yang, Longxiang Gao, and Yong Xiang. 2023. "Hybrid Variational Autoencoder for Time Series Forecasting." Knowledge-Based Systems 281: 111079. PDF.
- Dang-Quang, Nhat-Minh, and Myungsik Yoo. 2022. "An Efficient Multivariate Autoscaling Framework Using Bi-LSTM for Cloud Computing." Applied Sciences 12 (7): 3523. PDF.
- Hochreiter, Sepp, and Jürgen Schmidhuber. 1997. "Long Short-Term Memory." Neural Computation 9 (8): 1735–1780. PDF.
- Lackinger, Anna, et al. 2024. "Time Series Predictions for Cloud Workloads: A Comprehensive Evaluation." U Proceedings of the IEEE International Conference on Service-Oriented System Engineering. PDF.
- Ouhame, Soukaina, and Youssef Hadi. 2019. "Multivariate Workload Prediction Using Vector Autoregressive and Stacked LSTM Models." U Proceedings of the New Challenges in Data Sciences Conference. PDF.

@Large Research Group. n.d. "GWA-T-12 BitBrains." Grid Workloads Archive. PDF.

Shen, Siqu, Vincent van Beek, and Alexandru Iosup. 2015. "Statistical Characterization of Business-Critical Workloads Hosted in Cloud Datacenters." U Proceedings of the IEEE/ACM International Symposium on Cluster, Cloud and Grid Computing. PDF.