

Predviđanje sistemskih metrika virtuelne mašine

Poređenje linearnih i nelinearnih modela vremenskih serija

Dimitrije Spasojević

Računarska inteligencija

6. mart 2026.

Cilj rada je predviđanje budućih vrednosti sistemskih metrika virtuelne mašine na osnovu prethodno posmatrane istorije.

Posmatrane metrike su:

- CPU usage [%]
- Memory usage [KB]
- Disk read throughput [KB/s]
- Disk write throughput [KB/s]
- Network received throughput [KB/s]
- Network transmitted throughput [KB/s]

Problem je formulisan kao **jednokoračno predviđanje** multivarijantne vremenske serije.

Korišćen je **Bitbrains** dataset sa tragovima rada virtuelnih mašina.

U ovom radu analizirana je jedna virtuelna mašina:

- **VM 1000**
- period uzorkovanja: **5 minuta**
- broj atributa: **6**

Podela skupa:

- trening: 70%
- validacija: 15%
- test: 15%

Glavni koraci preprocesiranja:

- 1 učitavanje CSV-a
- 2 izbor šest relevantnih dinamičkih metrika
- 3 popunjavanje nedostajućih vrednosti metodom `forward fill`
- 4 hronološka podela na trening, validacioni i test skup
- 5 standardizacija korišćenjem statistika sa trening skupa

Time je obezbeđeno:

- da nema curenja informacija iz validacije i testa
- da su svi modeli trenirani u istim uslovima

Formiranje prozora vremenske serije

Problem predviđanja je transformisan u problem nadgledanog učenja.



Korišćena je sledeća formulacija:

- ulazni prozor: prethodnih **12 vremenskih koraka**
- to odgovara istoriji od **1 sata**
- cilj: vrednost u **sledećem vremenskom koraku**


Dakle, model uči preslikavanje:

$$(x_{t-11}, x_{t-10}, \dots, x_t) \mapsto x_{t+1}$$

Vizuelizacija vremenskih serija




Korelacije između metrika




Autokorelacija

Autocorrelation — CPU usage [%]



Autocorrelation — Memory usage [KB]



U radu su implementirana i upoređena sledeća rešenja:

- **Persistence baseline**

$$\hat{y}_{t+1} = y_t$$

- **Ridge regression** nad spljoštenim prozorima
- **VAR** — vektorska autoregresija
- **LSTM** — rekurentna neuronska mreža
- **Autoencoder + GRU** u latentnom prostoru

Za nelinearno modelovanje korišćen je LSTM model.

Konfiguracija:

- ulaz: sekvenca dužine 12
- broj ulaznih obeležja: 6
- skrivena dimenzija: 32
- izlaz: predikcija sledećeg stanja sistema

Dodatno je testiran pristup u latentnom prostoru:

- 1 autoencoder kompresuje ulaz sa 6 na latentne dimenzije
- 2 GRU predviđa sledeći latentni vektor
- 3 decoder vraća predikciju u originalni prostor metrika

Ideja:

- proveriti da li kompaktnija reprezentacija stanja sistema olakšava forecasting

Eksperimentalno okruženje

Eksperimenti su pokrenuti u sledećem okruženju:

- operativni sistem: Linux / Pop_OS
- programski jezik: Python 3
- biblioteke: NumPy, Pandas, scikit-learn, statsmodels, PyTorch
- izvršavanje LSTM i autoencoder modela na CPU-u

Evaluacija je vršena korišćenjem:

- MAE
- RMSE
- per-feature RMSE u originalnim jedinicama

Model	Test scaled RMSE
Persistence	1.2677
Ridge Regression	0.5157
VAR	0.5158
LSTM	0.4866
Autoencoder + GRU	0.5359

Glavni zaključci:

- persistence baseline je najslabiji, što znači da signal nije trivijalno konstantan
- linearni modeli uspešno opisuju veći deo dinamike sistema
- LSTM daje dodatno poboljšanje u odnosu na Ridge i VAR
- autoencoder kompresija nije unapredila forecasting u odnosu na direktni LSTM
- skup podataka pokazuje jaku vremensku autokorelaciju

Mogući pravci daljeg rada:

- analiza više VM-ova
- ispitivanje dužih vremenskih prozora
- testiranje naprednijih arhitektura